FUTURE TECH LEADERS BRASIL
SPACE TECH BOOTCAMP 2026

SUBMISSÃO DA PROPOSTA DE PROJETO FINAL

- **Nome:** João Henrique Pereira da Penha | **E-mail:** jhppenha@gmail.com
- **Repositório GitHub:** https://github.com/joaohppenha/qbillings

1. IDEIA DO PROJETO E DEFINIÇÃO DO PROBLEMA

Título do Projeto: Q-Billings: Monitoramento Espacial de Mananciais e Otimização Quântica de Patrulhamento Ambiental em São Bernardo do Campo.

A Represa Billings, em São Bernardo do Campo (SBC), é estratégica no abastecimento hídrico da Região Metropolitana de São Paulo, porém, a represa e a vegetação de Mata Atlântica de sua Área de Proteção Ambiental sofrem constante degradação humana (desmatamento ilegal, loteamentos clandestinos, pesca predatória e efluentes). A fiscalização em território extenso e acidentado impõe barreiras logísticas aos órgãos municipais, e, também, a escassez de recursos e o processamento analógico de dados geográficos retardam a resposta a infrações. Para resolver essa questão, o presente projeto visa desenvolver um sistema inteligente automatizado que utiliza processamento digital de imagens de satélite para detectar anomalias na cobertura vegetal da Billings, aplicando algoritmos quânticos combinatórios na roteirização otimizada das equipes de fiscalização e patrulhamento náutico da Guarda Ambiental de SBC.

2. RELEVÂNCIA PARA OS OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL (ODS)

A proposta fundamenta-se nas metas da Agenda 2030 das Nações Unidas:

- **ODS 6 (Água Potável e Saneamento):** Mitigação da degradação das margens hídricas e controle da integridade ambiental do reservatório.
- **ODS 15 (Vida Terrestre):** Combate à supressão ilegal de vegetação nativa e conservação da biodiversidade da Mata Atlântica municipal.

A contribuição prática cria um fluxo integrado em tempo real: a análise orbital indica a localização da perturbação; simultaneamente, o processador quântico estabelece rotas ideais de menor pegada de carbono para despacho rápido da patrulha local, reduzindo o tempo de avanço do dano ecológico.

3. EXEMPLOS DE LITERATURA

A modelagem ampara-se nas seguintes referências científicas:

GRZESIAK, M.; THAKKAR, P. **Flood Prediction Using Classical and Quantum Machine Learning Models**. *arXiv preprint arXiv:2407.01001*, 2024. Disponível em: arxiv.org. Acesso em: 31 out. 2026.
Valida o uso de circuitos quânticos variacionais (VQC) no sensoriamento remoto para resposta a desastres socioambientais.

MACIEL, D. A. *et al*. Machine learning for cyanobacteria mapping on tropical urban reservoirs using PRISMA hyperspectral data. **ISPRS Journal of Photogrammetry and Remote Sensing**, v. 202, p. 118-137, 2023. Disponível em: sciencedirect.com. Acesso em: 31 out. 2026.
Oferece base de validação local em SBC aplicando modelos preditivos à análise espectral na Represa Billings.

MAGDY, A.; SABEK, I.; YOUSSEF, M. Quantum Computing: A Brief Introduction and Its Applications in Spatial Computing. **ACM Transactions on Spatial Algorithms and Systems**, 2026. Disponível em: acm.org. Acesso em: 31 out. 2026.
Demonstra a conversão matemática de restrições espaciais e rotas geográficas no formato QUBO.

4. DESCRIÇÃO DOS DADOS

O *pipeline* operará com duas categorias de matrizes geográficas:

- **Dados Matriciais (Raster):** Imagens multiespectrais/hiperespectrais orbitais abertas (Sentinel-2, CBERS-4A ou Amazonia-1), cobrindo o pós-balsa e margens da Represa Billings (GeoTIFF).
- **Dados Vetoriais:** Malha hidrográfica e vias rodoviárias/náuticas de SBC via OpenStreetMap ou dados abertos municipais (GeoJSON/Shapefile).
- **Pré-processamento:** Recorte espacial da área via rasterio, correções atmosféricas, normalização radiométrica e fatiamento das imagens em patches de 256x256 pixels.

5. METODOLOGIA

Empregar-se-á arquitetura híbrida de *Deep Learning* e otimização clássico-quântica em nuvem (Google Colab). O *Deep Learning* justifica-se pela complexidade do sensoriamento remoto de alta resolução, superando falhas de algoritmos tradicionais em variações texturais de dossel e margens.

Etapas operacionais sequenciais:

1. **Segmentação Clássica:** Treinamento de CNN profunda U-Net com backbone ResNet-18 para gerar máscaras binárias dos pixels com supressão vegetal recente a partir dos patches.
2. **Conversão Geoespacial (GIS):** Vetorização em tempo real dos clusters de desmatamento em polígonos via GeoPandas (extraindo coordenadas exatas) e geração de grafo topológico da rede viária/hidrográfica via NetworkX.
3. **Módulo Quântico de Roteamento:** Transformação dos alvos e restrições da Guarda Ambiental em modelos QUBO. Execução no Qiskit Optimization com algoritmo variacional QAOA e Aer Simulator para determinar a sequência ótima de intervenção com menor deslocamento e custo temporal.